

# 模式识别笔记

陈鸿峥

2019.12\*

## 目录

1 简介	1
2 贝叶斯决策论	2

## 1 简介

机器学习侧重于处理的算法，而模式识别则包括了数据预处理、实际运算和数据输出的完整过程。

- 模式识别：涵盖的范围广，包括特征提取、特征选择、降维、各种分类器等。
- 机器学习：主要是讲学习，更多关于分类器如何训练模型，而不涉及特征方面的知识。

良好特征的四个特点：

- 可区别性（不同类）
- 可靠性（同类）
- 独立性（特征之间）
- 参数少（复杂性）

一个对象的所有特征参数组成特征向量。同样需要从高维测量空间（样本）中提取特征映射到低维特征空间。

模式识别分为两类

- 结构/句法模式识别
- 统计/神经网络模式识别

---

\*Build 20191207

## 2 贝叶斯决策论

### 2.1 离散变量

处于类别 $\omega_i$ 并具有特征值 $x$ ，有后验概率<sup>1</sup>

$$\mathbb{P}(\omega_i | x) = \frac{p(x | \omega_i)\mathbb{P}(\omega_i)}{p(x)}$$

即

$$posterior = \frac{likelihood \times prior}{evidence}$$

无论什么情况，当我们观察到特定的 $x$ ，对于二分类问题有错误率

$$\mathbb{P}(error | x) = \begin{cases} \mathbb{P}(\omega_1 | x) & \text{决策}\omega_2 \\ \mathbb{P}(\omega_2 | x) & \text{决策}\omega_1 \end{cases} = \min[\mathbb{P}(\omega_1 | x), \mathbb{P}(\omega_2 | x)]$$

平均错误概率可表示为

$$\mathbb{P}(error | x) = \int_{-\infty}^{\infty} \mathbb{P}(error, x) dx = \int_{-\infty}^{\infty} \mathbb{P}(error | x) p(x) dx$$

注意 $p(x)$ 是证据，可以看为是固定分布（常量）。

**定理 1** (贝叶斯决策/最小错误率准则). 若 $P(\omega_1 | x) > P(\omega_2 | x)$ ，则判定类别为 $\omega_1$ ；否则判为 $\omega_2$ 。依照这种准则可以获得最小错误率，即 $P(error | x) = \min[P(\omega_1 | x), P(\omega_2 | x)]$

### 2.2 连续变量

考虑特征向量 $\mathbf{x} \in \mathbb{R}^d$ （ $\mathbb{R}^d$ 称为特征空间），令 $\{\omega_1, \dots, \omega_c\}$ 表示有限的 $c$ 个类别集， $\{\alpha_1, \dots, \alpha_a\}$ 表示有限的 $a$ 种可能采取的行为集，损失函数(loss) $\lambda(\alpha_t | \omega_j)$ 描述类别状态为 $\omega_j$ 时采取行动 $\alpha_t$ 的风险。 $p(\mathbf{x} | \omega_j)$ 表示在真实类别为 $\omega_j$ 的条件下 $\mathbf{x}$ 的概率密度函数， $P(\omega_j)$ 表示类别处于状态 $\omega_j$ 时的先验概率，后验概率 $P(\omega_j | \mathbf{x})$ 则通过贝叶斯公式

$$P(\omega_j | \mathbf{x}) = \frac{p(\mathbf{x} | \omega_j)P(\omega_j)}{p(\mathbf{x})}$$

计算得到，证据变为

$$p(\mathbf{x}) = \sum_{j=1}^c p(\mathbf{x} | \omega_j)P(\omega_j)$$

与行动 $\alpha_i$ 相关联的风险(risk)为

$$R(\alpha_i | \mathbf{x}) = \sum_{j=1}^c \lambda(\alpha_i | \omega_j)\mathbb{P}(\omega_j | \mathbf{x})$$

---

<sup>1</sup>通常用 $p(\cdot)$ 代表概率密度函数（连续变量），用 $\mathbb{P}(\cdot)$ 代表概率质量函数（离散变量）

进而得到总损失

$$R = \int R(\alpha(\mathbf{x}) \mid \mathbf{x}) p(\mathbf{x}) \, d\mathbf{x}$$

因此得到连续情形下的贝叶斯决策论：

**定理 2.** 为最小化 $R$ ，计算条件概率

$$R(\alpha_i \mid \mathbf{x}) = \sum_{j=1}^c \lambda(\alpha_i \mid \omega_j) \mathbb{P}(\omega_j \mid \mathbf{x}), \quad \forall i = 1, \dots, a$$

选择 $\alpha_i$ 使得 $R(\alpha_i \mid \mathbf{x})$ 最小，进而最小化总的风险即称为贝叶斯风险，记为 $R^*$

对称损失/0-1损失

$$\lambda(\alpha_i \mid \omega_j) = \begin{cases} 0 & i = j \\ 1 & i \neq j \end{cases} \quad i, j = 1, 2, \dots, c$$

有条件风险

$$\begin{cases} R(\alpha_1 \mid \mathbf{x}) &= \lambda_{11} P(\omega_1 \mid \mathbf{x}) + \lambda_{12} P(\omega_2 \mid \mathbf{x}) \\ R(\alpha_2 \mid \mathbf{x}) &= \lambda_{21} P(\omega_1 \mid \mathbf{x}) + \lambda_{22} P(\omega_2 \mid \mathbf{x}) \end{cases}$$